



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

석사학위논문

딥 러닝 기법을 이용한 노면 상태 분류 알고리즘

Algorithm for Road Condition Classification
Using Deep Learning

이 우 성

한양대학교 대학원

2018 년 2 월

석사학위논문

딥 러닝 기법을 이용한 노면 상태 분류 알고리즘

Algorithm for Road Condition Classification
Using Deep Learning

지도교수 허 건 수

이 논문을 공학 석사학위논문으로 제출합니다.

2018 년 2 월

한양대학교 대학원

자동차전자제어공학과

이 우 성

이 논문을 이우성의 석사학위 논문으로 인준함

2018 년 2 월

심사위원장 홍 정 표



심사위원 허 건 수



심사위원 선우 명 호



한양대학교 대학원

차 례

차례	1
국문요지	2
Nomenclature	3
List of Figures.....	4
List of Tables.....	4
1. 서론	5
1.1 연구 배경과 목적	5
1.2 연구 목표	6
1.3 연구 동향	7
1.4 연구 내용	9
2. Feature Selection	10
2.1 Feature selection 개요.....	10
2.2 Feature selection 연구 동향.....	11
2.3 Feature selection 컨셉.....	12
2.4 Feature selection 진행 결과.....	14
3. 딥 러닝 네트워크 구조.....	17
3.1 딥 러닝 네트워크 개요.....	17
3.2 Convolutional Neural Network 구조 설계.....	18
4. 실차 데이터 기반 검증	23
4.1 실차 데이터 기반 검증 개요.....	23
4.2 판단 대상 노면 선정.....	23
4.3 노면 판단 결과.....	25
5. 결론	35
참고문헌	36
ABSTRACT	37

국문요지

최근 차량의 승차감과 조종안정성의 양립을 위해 많은 자동차 회사들이 능동 현가장치 제어 시스템에 대한 연구가 많이 이루어지고 있다. 네 바퀴에 들어오는 노면 입력을 각각 판단하여 그에 대응하도록 댐핑을 조절하여 승차감을 향상시키고자 하는 시스템이 존재한다. 또한 차량의 물각과 노면과의 슬립 정도를 판단하여 서스펜션의 단단한 정도를 조절해주는 제어 시스템에 대한 연구도 활발히 이루어지고 있다. 이렇듯, 능동 현가장치 제어 시스템에 있어서 노면 상태에 대한 정보가 굉장히 중요한 요소이다.

본 논문에서는 차량 내부에 장착되어 CAN으로 받을 수 있는 신호를 이용하여 딥 러닝 기법을 통해 노면 상태를 분류하는 알고리즘을 제안한다. 노면 상태와 관련되어있고 CAN으로부터 받을 수 있는 센서 값들 중, 어느 센서 값이 노면 상태 분류에 중요한 인자인지를 판단하는 연구를 수행한다. 그 후, 선택된 중요한 센서 값들을 사용하여 딥 러닝 기법 중 특징추출에 강점을 가지고 있는 Convolutional Neural Network를 이용한 알고리즘을 설계한다.

제안하는 노면 상태 분류 알고리즘을 실차 데이터 기반으로 성능을 검증한 후 어느 정도의 노면 분류 정확도를 확보하는지 분석하였다.

Nomenclature

a_{z_FL} : vertical acceleration at front left of a vehicle, m/s^2

a_{z_FR} : vertical acceleration at front right of a vehicle, m/s^2

a_{z_RR} : vertical acceleration at rear right of a vehicle, m/s^2

v_{x_FL} : wheel angular speed at front left of a vehicle, deg/s

v_{x_FR} : wheel angular speed at front right of a vehicle, deg/s

v_{x_RL} : wheel angular speed at rear left of a vehicle, deg/s

v_{x_RR} : wheel angular speed at rear right of a vehicle, deg/s

a_y : lateral acceleration at the c.g. of a vehicle, m/s^2

a_x : longitudinal acceleration at the c.g. of a vehicle, m/s^2

$\dot{\psi}$: yaw rate of a vehicle, rad/s

v_x : longitudinal velocity of a vehicle, m/s

δ : steering angle , deg

$\dot{\delta}$: steering angle rate , deg/s

List of Figures

Figure 1.3.1 노면 분류를 위한 neural network 기반 알고리즘 (EM Dupont <i>et al.</i>)	6
Figure 1.3.2 노면 형상 추정을 위한 wavelet neural network 기반 알고리즘 (Ali Solhmizaei <i>et al.</i>)	7
Figure 1.3.3 노면 형상 추정을 위한 차량 센서 값 및 칼만필터 기반 알고리즘 (Doumiati <i>et al.</i>)	7
Figure 1.4.1 Algorithm structure	8
Figure 1.2.1 Proposed feature selection method (Nicole et al., 2016)	11
Figure 2.3.1 제안하는 feature selection 과정	13
Figure 3.1.1 CNN의 전체적인 과정	17
Figure 3.2.1 ReLU 및 eLU 함수 비교	19
Figure 2.2.2 제안하는 CNN 구조	21
Figure 3.1.1 판단 대상 노면	23
Figure 4.3.1 일반 범용로 판단 결과	24
Figure 4.3.2 장파로 판단 결과	25
Figure 4.3.3 배수로 / 맨홀 및 포트홀 판단 결과	28
Figure 4.3.4 범프 판단 결과	31
Figure 4.3.5 학습하지 않은 범프를 포함한 판단 결과 그래프	32

List of Tables

Table 1.2 연구 목표	5
Table 2.1.1 실차 취득 데이터 종류	7
Table 2.4.1 Feature selection 적용 결과	14
Table 2.4.2 선별된 feature를 사용하여 CNN에 적용하였을 때의 노면 판단 정확도	15
Table 4.1.1 노면 상태에 따른 라벨링	23
Table 4.3.1 노면 상태에 따른 훈련 데이터 개수 비교	26
Table 4.3.2 맨홀 및 포트홀 노면 상태의 속도에 따른 정확도 비교	27
Table 4.3.3. 속도에 따른 범프 시나리오 구성 및 판단 정확도	29
Table 4.3.4 학습하지 않은 범프를 포함한 판단 결과	30
Table 4.3.5. 각 노면에 대한 판단 정확도	33

제1장 서론

1.1 연구배경과 목적

최근 많은 자동차 OEM에서 운전자 및 동승자의 승차감과 조종안정성을 향상시키기 위한 능동 현가 제어 시스템에 대한 연구를 활발하게 진행 중이다. 이와 관련하여 Active 현가장치 및 Semi-Active 현가장치와 같이 제어 전략을 수립하여 승차감 및 조종안정성 관련 성능을 향상시키기 위한 다양한 현가장치 제어기 개발을 수행 중이다.

노면상태에 대한 정보는 능동 현가장치 제어 전략 수립에 중요한 역할을 한다. 자동차 전용 도로 및 고속도로의 경우에는 주행 안정성 향상을 위한 제어가 필요하며, 비포장도로에서는 승차감 향상을 위한 제어, 일반도로에서는 승차감과 주행 안정성의 양립을 위한 제어가 필요하다. 따라서 노면상태를 현가장치 제어기에 정확히 알려 주는 것은 승차감 및 조종안정성의 향상에 있어 결정적인 요소이다.

본 연구에서는 능동 현가 제어 시스템에 도움을 주기 위해 노면상태 판단 정확도를 향상하고자 한다. 이를 위해 딥 러닝 기법을 이용하였다. 딥 러닝이란 컴퓨터가 다양한 데이터를 분석함으로써 어떠한 문제에 대한 답을 도출할 수 있는 구조를 학습시키는 기법이다. 이는 다층구조 형태의 신경망을 이루고 있으며 주로 분류(Classification)에 많이 쓰인다. 본 연구에서는 차량의 다양한 데이터를 통해 노면 상태를 정확히 분류하는 것이 목표이므로 딥 러닝을

이용하는 것이 적합하다고 판단하였다. 또한 딥 러닝의 입력, 즉, feature로 쓰이는 여러 차량 센서들 중 노면판단에 중요한 feature를 선정하였다. 차량 센서는 비용을 고려하여 실제 차량에 장착되어 있는 센서들을 사용하였다. 딥 러닝 기반 노면상태 판단 알고리즘에 대해 최적화를 실시한 후, 실차 데이터 기반으로 성능을 검토하였다.

1.2 연구 목표

본 연구에서는 크게 두 가지 목표를 설정하였다. 정량적 목표로는 판단 대상 5가지 노면에 대해 전체 판단 정확도 90%이상을 확보하는 것이다. 이를 위해 딥 러닝 기법 중 Convolutional Neural Network(CNN)을 사용하였다. CNN은 특징 추출에 강점이 있으므로 각 노면 상태에 대한 차량 센서 값들을 활용하면 정확도를 확보하는데 도움을 줄 것이라 생각하였다.

정성적 목표로는 노면 분류에 사용할 수 있는 핵심인자를 판별하는 것이다. 어떠한 센서 정보가 노면 분류에 있어 중요한지 선정하는 것을 목표로 삼았다.

정량적 목표	정성적 목표
5 가지의 노면 상태에 대해 전체 판단 정확도 90% 이상 확보	노면 상태 분류에 있어 핵심적인 feature 선정

Table 1.2 연구 목표

1.3 연구 동향

노면에 대한 정보를 알기 위한 연구는 많이 진행되어 왔다. Figure 1.2.1 과 Figure 1.2.2 에서 제안하는 방법은 neural network를 사용한 연구이며 Figure 1.2.3에서 진행한 연구는 차량 수직 가속도 센서를 이용하여 노면 형상을 추정하고 있다.

EM Dupont 등은 분류 대상 노면을 Packed/Loose Gravel, Sparse/Tall Grass, Asphalt, Sand의 6가지로 지정하였다. 차량의 x방향 가속도, y방향 가속도, z방향 가속도의 측정값을 이용하였는데 Fast Fourier Transform (FFT)를 이용하여 frequency domain에서 feature를 추출하였다. 이러한 feature들과 각 노면에 대해 얻은 다른 속도들의 정보를 활용하여 neural network를 구성하여 어떤 노면인지 분류해주는 알고리즘을 제안하였다. Figure 1.3.1(a)에서 알고리즘의 구조를 나타내며 Figure 1.3.1(b)에서 각 노면에서 FFT를 통헤 나온 feature들의 분포를 나타내고 있다. [1]

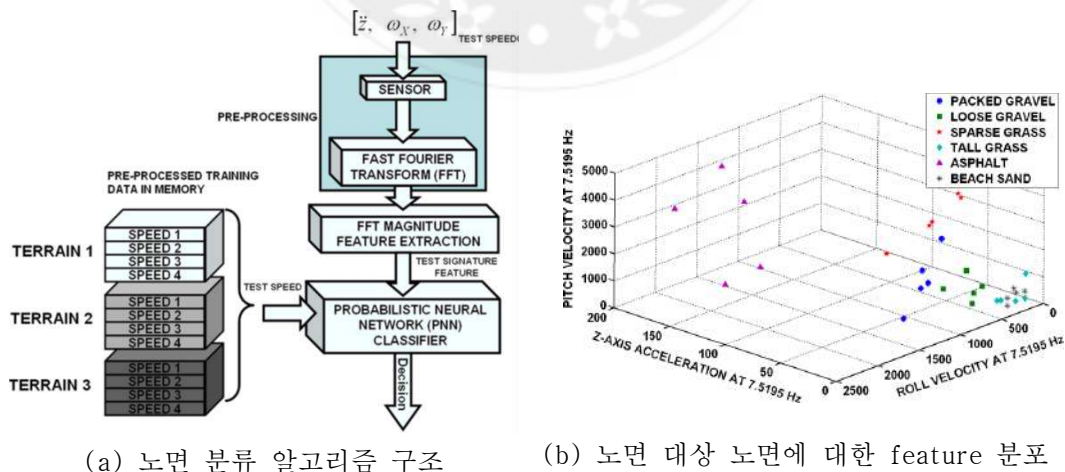


Figure 1.3.1 노면 분류를 위한 neural network 기반 알고리즘 (EM Dupont *et al.*)

Ali Solhmizaei 등은 7자유도 full car 모델 기반으로 얻은 노면 형상에 대한 차량 가속도 반응 및 노면 형상 정답 데이터를 이용하여 wavelet neural network를 구성하였다. 이를 학습시켜 노면 형상을 추정하는 방법을 제시하였다. Figure 1.3.2의 (a)가 사용한 7자유도 full car 모델이며 (b)에서 네트워크의 구조를 나타내고 있다. [2]




Figure 1.3.2 노면 형상 추정을 위한 wavelet neural network 기반 알고리즘 (Ali Solhmizaei *et al.*)

Doumiati 등은 노면 형상을 추정하기 위해 quarter car 모델을 이용하였다. 모델을 바탕으로 수직 가속도 값과 현가 장치의 인장 또는 압축 정도에 대한 값을 받은 후 칼만 필터를 이용하여 노면 형상을 추정하였다. [3]

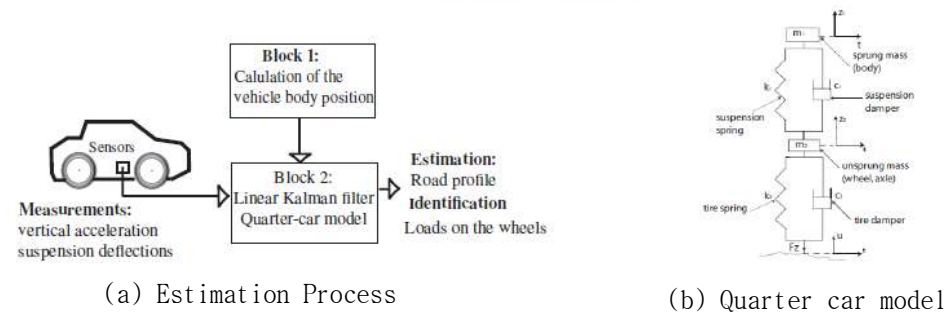


Figure 1.3.3 노면 형상 추정을 위한 차량 센서 값 및 칼만필터 기반 알고리즘 (Doumiati *et al.*)

1.4 연구 내용

본 논문에서는 딥 러닝 기법 중 CNN을 이용하여 노면 상태를 분류하는 알고리즘을 제안한다. 알고리즘의 구성은 다음과 같다.

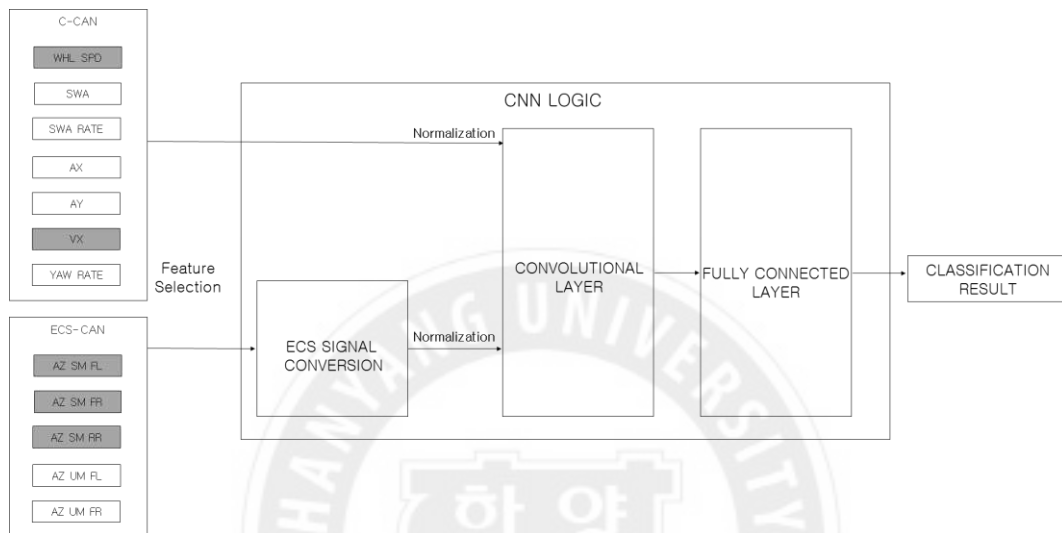


Figure 1.4.1 Algorithm structure

알고리즘은 크게 3가지 블록으로 구성되어있다. 가장 처음으로 차량 CAN 신호를 받아 어떤 센서 값이 노면 상태 분류에 있어 필요한 정보인지를 판단하는 Feature Selection 블록이다. C-CAN과 ECS-CAN으로부터 받은 값들 중 어떤 센서가 중요한지 판단한다. 이렇게 단위가 다른 센서 값들을 이용하여 CNN을 진행하면 큰 값들만 남기 때문에 결과에 많은 오차가 발생할 수 있다. 따라서 Mean normalization을 진행하여 모든 센서 값이 0에서 1사이의 값으로 가지도록 한다. 이러한 센서 값으로 학습을 실시한 후, 최종적으로 나타나는 Convolution layer와 Fully connected layer의 가중치 값으로 CNN LOGIC 블록을 구성한다. 최종적으로 새로운 노면에서 들어오는 센서 값을 통해 노면 상태 분류 결과를 나타낸다.

제2장 Feature Selection

2.1 Feature selection 개요

Feature는 딥 러닝의 입력으로 사용되는 인자들을 의미한다. 본 논문에서는 실차에서 CAN으로부터 받은 센서 정보를 feature로 선정하였다. Feature는 딥 러닝 알고리즘의 정확도와 큰 영향이 있는데, 최종적으로 분류하고자 하는 대상의 특징을 잘 나타내는 feature를 선정하여 딥 러닝의 입력으로 사용하는 것이 중요하다.

Feature의 개수가 너무 많으면 데이터 용량 과다로 인한 연산량 증가 등의 문제가 발생한다. 따라서 feature의 수는 최소화 시키면서 알고리즘의 분류 정확도를 확보하는 feature의 선정이 중요하다.

본 논문에서는 실차 실험을 통해 얻은 15개의 센서 정보 중, 연구의 목표인 노면 판단에 있어 중요한 feature 들을 찾아내는 feature selection에 대한 연구를 진행하였다. 15개의 센서 정보는 Figure 4.1.1에서 보이는 실험 대상 노면에서 실차를 통해 CAN으로 받은 신호들이다. 크게 현가장치 제어와 관련된 ECS-CAN과 차량의 동역학적인 정보와 관련된 Chassis-CAN을 통해 데이터들을 취득하였다. 취득한 센서 데이터의 종류는 Table 2.1.1에서 보이고 있다.

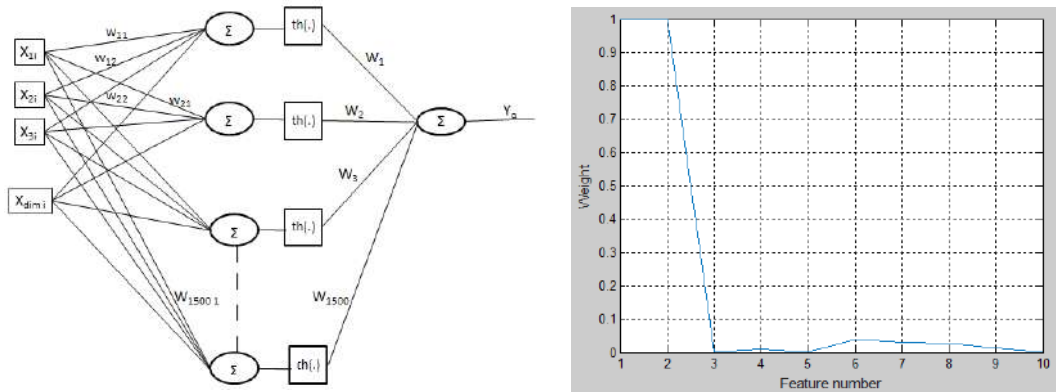
취득 데이터 종류	
Suspension 관련	Vehicle motion 관련
ECS wheel vertical acceleration (a_{z_FL} a_{z_FR})	Wheel speed (v_{x_FL} v_{x_FR} v_{x_RR} v_{x_RL})
ECS body vertical acceleration (a_{z_FL} a_{z_FR} a_{z_RR})	Vehicle speed (v_x)
	Longitudinal acceleration (a_x)
	Lateral acceleration (a_y)
	Steering angle (δ)
	Steering angle speed ($\dot{\delta}$)
	Yaw rate ($\dot{\psi}$)

Table 2.1.1 실차 취득 데이터 종류

2.2 Feature selection 연구 동향

Nicole Challita 등은 hidden layer가 1개로 구성된 뉴럴 네트워크 구조를 이용하여 feature selection 방법을 제시하였다. 뉴럴 네트워크의 각 feature에 곱한 가중치의 크기를 통해 feature의 중요도를 판단하였다. [4]

아래 그림의 (a)와 같이 모델을 구성한 후 에러를 설정하여 이를 최소화할 수 있도록 가중치의 값을 계산하였다. 모델을 거친 결과를 (b)에서 나타내고 있는데 가중치 값이 클수록 중요한 feature라고 판단할 수 있다.



(a) Model of feature selection

(b) Weight for each features

Figure 4.2.1 Proposed feature selection method (Nicole et al., 2016)

2.3 Feature selection 컨셉

CNN기반에서 feature selection을 진행하기 위하여 크게 두 단계로 나누어 학습을 진행하였다. Importance weight layer에서는 importance weight를 네트워크 가장 앞부분에 추가하여 weight와 입력이 1대1 대응되어 입력 값을 선형 변환하여 전달하게 된다. 이 때, 1 norm을 추가시키는데 importance weight의 크기가 줄어들어야 cost가 줄어들어 importance weight가 작아지는 방향으로 최적화를 진행하기 위함이다. 최종적으로 판단 정확도를 나타내는 cost와 importance weight의 1 norm cost가 평형 하는 지점에서 최적화가 수렴된다. Importance weight layer를 학습시키는 이유는 어떤 feature가 노면 판단에 있어서 중요한 역할을 하는지 알아내기 위함이다.

CNN layer는 학습에 사용된 CNN과 동일하며 CNN layer를 학습시키는 이유는 알고리즘의 판단 정확도를 확보하기 위함이다. 이렇게 2단계로 학습을 분리한 이유는 한번에 모든 변수를 학습시키면 importance weight가 0 근처인 값일 때, 뒤쪽 CNN layer가 큰 값으로 최적화가 진행되는 경우가 발생할 수 있다. 이 때, importance weight는 작은 값이지만 노면 판단에 중요한 역할을 한다는 결과가 나오는 상황이 일어날 수 있다. 이러한 현상을 방지하기 위해 두 단계로 나누었다.

학습 진행 순서는 1단계에서 CNN layer를 학습시킴으로써 노면 판단 정확도를 확보한 후, 2단계에서 importance weight layer를 학습시켜 어떠한 feature가 노면 판단에 있어 중요한지를 판단한다. Figure 2.3.1에서 전체적인 과정을 나타내고 있다.

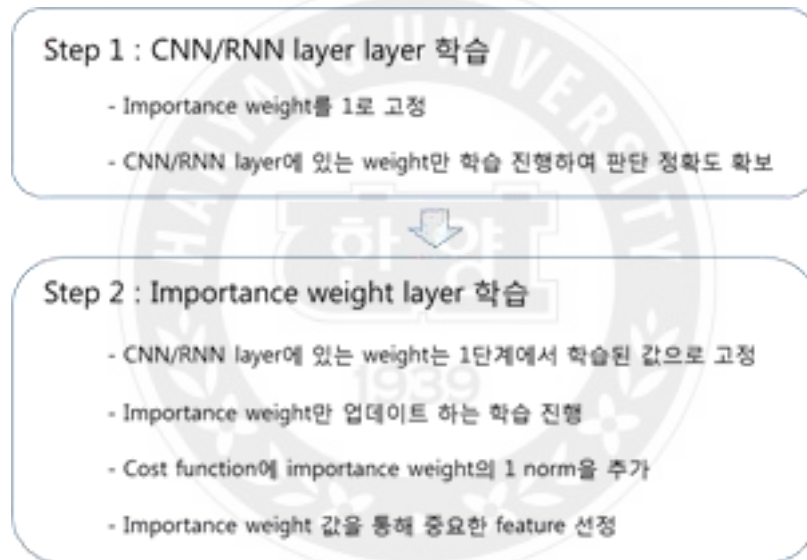
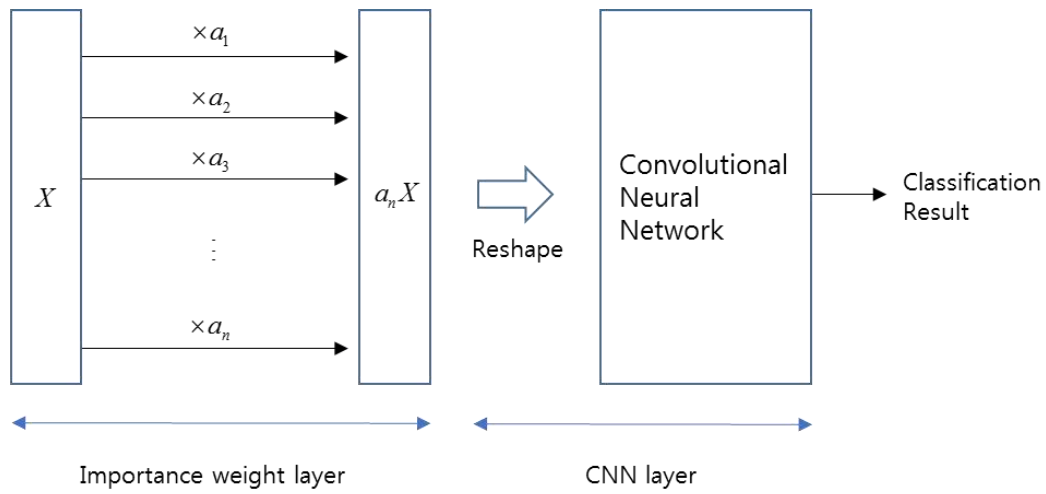


Figure 2.3.1 제안하는 feature selection 과정

2.4 Feature selection 진행 결과

2.3에서 제안한 feature selection 방법을 적용하였다. 중요한 feature 만 남기기 위해서 feature selection을 총 2회 적용하였다. 1회 적용하였을

때 영향도가 낮게 판단된 feature를 제외하고 한번 더 feature selection을 적용하여 더 중요한 feature들을 선별하였다. 그 결과를 아래 표에서 나타내고 있다. 총 15개 센서 중 7개의 feature만 중요한 인자로 나타났다. 그 결과를 Table 2.4.1에서 나타내고 있다.

센서	a_{z_FL} (body)	a_{z_FR} (body)	a_{z_RR} (body)	a_{z_FL} (wheel)	a_{z_FR} (wheel)	a_y	a_x
Step 1 정확도	0.86	1	0.94	0	0.47	0.77	0.66
Step 2 정확도	0.78	0.91	0.85	-	-	0.56	-

δ	$\dot{\delta}$	v_x	v_{x_FL}	v_{x_FR}	v_{x_RL}	v_{x_RR}	$\dot{\psi}$
0.56	0	0.82	0.9	0.9	0.91	0.89	0.7
-	-	0.76	0.73	0.72	0.72	0.64	0.52

Table 2.4.1 Feature selection 적용 결과

Feature selection을 적용하여 선별한 7개의 feature를 이용하여 노면 판단 로직을 학습시킨 결과는 아래 table 2.4.2과 같다. Label 2와 4의 정확도가 감소하는 것을 볼 수 있었으나 label 0과 1의 정확도는 소폭 증가하여 전체 정확도의 경우 큰 변화가 없는 것을 확인 할 수 있었다.

이러한 feature selection 과정을 통해 전체 정확도 측면에서 큰 손해 없이 CNN을 구성하는 가중치들의 개수와 복잡도가 줄어드는 이점을 얻을 수 있

었다. Feature의 개수가 15개에서 7개로 줄어들었을 때 CNN 네트워크 용량의 크기는 49% 감소하는 효과를 얻을 수 있었다.

Label	0	1	2	3	4	Total
Accuracy	96.1	97.0	86.2	95.4	51.2	92.9
(%)	(+1.1)	(+3.2)	(-9.1)	(-0.6)	(-4.2)	(-1.3)

Table 2.4.2 선별된 feature를 사용하여 CNN에 적용하였을 때의 노면 판단 정확도



제3장 딥 러닝 네트워크 구조

3.1 딥 러닝 네트워크 개요

노면 판단을 위한 딥 러닝구조로 CNN을 사용하였다. CNN은 생명 과학분야에서 아이디어를 얻어 출현하였다. 정보처리와 관계되는 동물의 세포에 대해 응답을 일으키는 자극의 영역은 특정 영역에 한정된다는 것이다. 이를 영상처리에 적용시켜보면, 영상에서 특정 위치에 있는 픽셀들은 그 주변에 있는 일부 픽셀들과만 상관관계가 높고 거리가 멀어지면 그 영향은 감소하게 된다. 이렇듯 전체 영역에 대해 동일한 중요도로 처리하기 보다는 특정 범위에 한정 짓고 처리를 하면 훨씬 효과적인 것이라 짐작할 수 있다.

따라서 CNN은 영상 및 음성 인식에 많이 쓰이며 locality를 가지는 모든 신호에도 유사하게 적용 가능하다.

CNN의 과정은 크게 convolution과 pooling으로 이루어져 있다. Convolution을 진행할 때는 convolution filter가 필요하다. Convolution 과정을 거치게 되면 입력에 대해 각각 다른 필터를 사용하여 필터마다 도드라지는 특징을 도출하고 그에 따른 feature map을 만들게 된다. 생성된 feature map에서 pooling 과정을 진행한다. 가장 많이 쓰는 방법은 max pooling 과 average pooling 두 가지가 있다. Max pooling은 지정한 크기의 영역에서 큰 값을 선택하여 정보를 압축하는 작업이다. Average pooling은 영역의 평균을 취하여 정보를 압축한다. 통상적으로 max pooling을 많이 사용하며 이는 강한

신호만을 전달해서 영역 내에서 도드라지는 특징을 파악한다. 이러한 convolution + pooling 과정을 반복적으로 거친 후 기본 artificial neural network의 구조를 거쳐 fully connected 과정을 수행하게 되며 최종적인 결과를 낸다. CNN의 전체적인 과정은 Figure 3.1.1에서 나타내고 있다. [8]

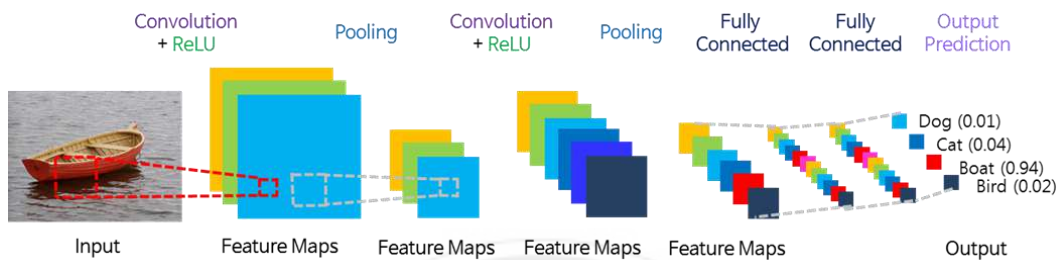


Figure 3.1.1 CNN의 전체적인 과정

3.2 Convolutional Neural Network 구조 설계

네트워크의 입력은 센서 feature selection을 통해 얻은 7개의 센서를 10ms 주기 800ms 동안의 데이터를 축적하여 80x7의 꼴을 reshape과정을 통해 20x28로 만들어주었다. CNN의 입력은 정사각형 꼴에 가까워야 더 좋은 결과를 낸다. Convolution이나 pooling을 거치면서 입력된 데이터 사이즈는 줄어들게 되는데, 직사각형 꼴이면 길이가 짧은 쪽 데이터들의 손실이 발생할 수 있다. 따라서 정사각형 꼴의 입력으로 넣어주는 것이 바람직하다.

20x28로 설정한 입력은 3x3 convolution filter를 통해 4층의 convolution layer를 통과하였다. Convolution filter는 각각 32개 64개 128개 64개를 가지고 있는 형태로 구성하였다.

Figure 3.1.1에서 보인 CNN구조를 보면 convolution filter를 거친 후에는 max pooling layer를 거치게 된다. 하지만 제안한 구조에는 max pooling 과정을 제외하였다. 사이즈를 줄인다는 장점을 가지고 있지만 노면 판단에 있어서는 센서 값을 큰 값을 제외하고 없애는 것과 같은 의미이다. 따라서 판단 정확도에 영향을 미치지 때문에 max pooling layer를 제외하였다.

모든 convolution layer를 통과한 데이터는 fully connected(FC) layer를 통과하기 위해 flatten 작업을 수행한다. Flatten 된 데이터는 뉴런의 개수가 1024개와 512개인 FC layer 2개를 통과하게 된다. 마지막에서는 softmax 함수를 사용하여 확률적으로 가장 높은 노면 상태를 판단하게 된다. 제안하는 전체적인 CNN구조를 Figure 3.2.2에서 보이고있다.

CNN 구조를 설계할 때, 모든 hidden layer는 eLU 함수를 사용하였다. ReLU는 Figure 3.2.1에서 보이듯이 0이하의 값에선 모두 0의 일정한 값을 가지게 된다. eLU 함수는 ReLU 함수를 조금 변형시킨 꼴인데 0보다 작은 값에 대해 어느 정도 음수 값을 취해주는 함수이다. 식 (3.1)이 ReLU함수를, 식 (3.2)가 eLU함수를 나타내고 있다. 차량 센서를 분석해보면 많은 음수 값들이 존재한다. 따라서 ReLU보다 eLU의 판단 정확도가 높을 것이라 판단하였다. ReLU와 eLU 함수에 대한 차이를 Figure 3.2.1에서 보이고 있다.

$$\max(0, x) \quad (3.1)$$

$$\begin{cases} x & x \geq 0 \\ a(e^x - 1) & x < 0 \end{cases} \quad (3.2)$$




Figure 3.2.1 ReLU 및 eLU 함수 비교

또한, 각 뉴런들의 초기값 설정이 중요하다. 제안한 네트워크를 구성하는 뉴런의 초기값을 설정할 때, He initialization을 사용하였다. 초기값 설정은 학습 정확도 뿐만 아니라 수렴 속도에 영향을 미친다. He initialization은 앞 계층의 뉴런의 수를 고려한 분산을 가지기 때문에 좋은 성능을 낸다고 알려져 있다. 따라서 노면 판단에 있어 학습될 뉴런들의 초기값을 He initialization을 통해 초기값을 설정하였다.

He initialization은 입력 층과 출력 층의 뉴런의 수를 고려한 분산을 가지게 된다. 이를 식(3.3)에서 나타내고 있다.

$$Var(W) = \frac{2}{n_{in} + n_{out}} \quad (3.3)$$

표준편차 분모 계수를 1이 아닌 2로 함으로써, 표준편차를 크게 하여 가중치의 초기값들이 넓게 분포된 형태로 만들기 위함이다.

CNN 구조를 설계하고 학습을 실시할 때 어떤 최적화 기법을 쓰느냐에 따라 어떻게 오차를 줄일지 결정된다. 본 연구에서는 Adam optimizer를 사용하였다. Adam optimizer는 운동량을 의미하는 momentum과 Ada Grad를 합친 기법이다.

Momentum에 대한 수식은 식 (3.4)에서 나타내고 있다. 식 (3.4)에서 W 는 가중치 변수라 볼 수 있으며, v 는 물리에서의 속도를 의미한다. 이는 기울기 방향으로 힘을 받아 물체가 가속되는 물리법칙을 나타내는 바와 같다.

$$v \leftarrow \alpha v - \eta \frac{\partial L}{\partial W} \quad W \leftarrow W + v \quad (3.4)$$

Ada Grad는 신경망 학습에서의 학습률인 η 를 조정하면서 학습을 진행하는 방식이다. 이는 각각의 매개변수에 맞춤형 값을 만들어 준다. Ada Grad에 대한 수식을 식 (3.5)에서 나타내고 있다. 식을 보면 가중치에 대한 손실의 기울기가 제공하여 계속 더해지게 된다. 그리고 가중치는 갱신할 때 마다 $\frac{1}{\sqrt{h}}$ 을 곱해 학습률을 조정한다. 이는 h 에 따라 가중치의 변화 정도가 다르게 적용되게 된다는 의미이다. 따라서 이는 최적 점을 향해 효율적으로 움직이게 된다. 처음에는 크게 변화하지만 그 큰 움직임에 비례하여 가중치의 갱신 정도도 큰 폭으로 작아지게 된다. 반면, 최적 점에 다가갈수록 h 가 작게 변화함에 따라 가중치의 갱신 정도도 작은 폭으로 최적 점을 향해 작아지게 된다.

$$\mathbf{h} \leftarrow \mathbf{h} + \frac{\partial L}{\partial \mathbf{W}} * \frac{\partial L}{\partial \mathbf{W}} \quad \mathbf{W} \leftarrow \mathbf{W} - \eta \frac{1}{\sqrt{\mathbf{h}}} \frac{\partial L}{\partial \mathbf{W}} \quad (3.5)$$

Adam은 이러한 두 가지를 합친 방법이다. 최적 점으로 향하는 공간을 효율적으로 탐색함과 동시에 학습의 갱신 강도를 적응적으로 조정할 수 있다는 장점을 가진 방법이다.

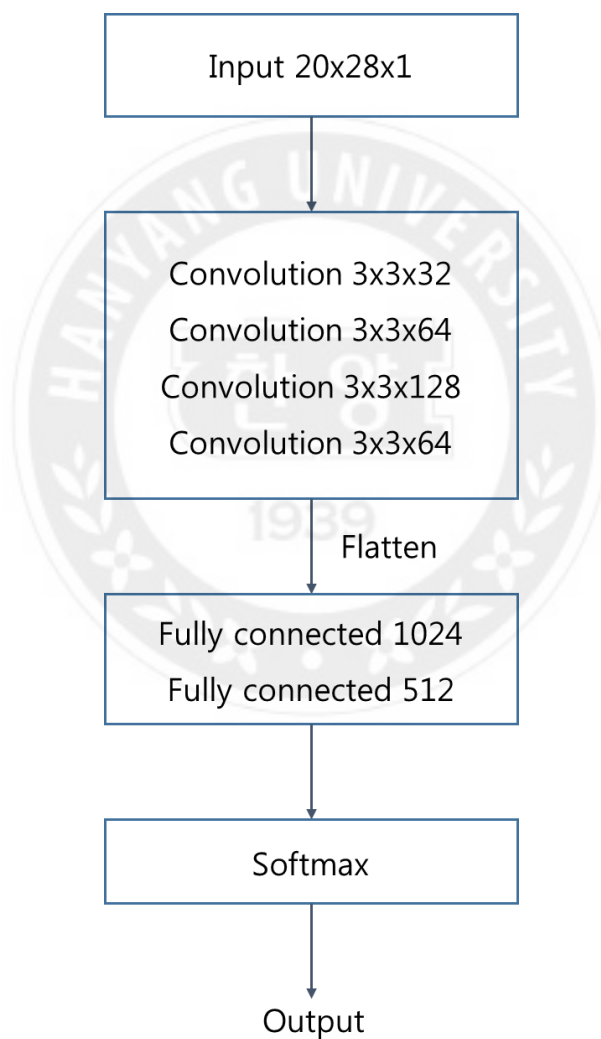


Figure 5.2.2 제안하는 CNN 구조

제4장 실차 데이터 기반 검증

4.1 실차 데이터 기반 검증 개요

다음 4.2절 에서 선정한 판단 대상 노면에서 얻은 실차 실험 데이터를 기반으로 Figure 3.2.2의 CNN 구조를 학습시킨다. 그 후 새로운 실차 데이터를 사용하여 노면 판단 로직의 정확도를 분석한다. 4.2의 판단 대상 노면 다섯 종류에 대한 노면 판단 로직 적용 결과를 4.3 ~ 4.6에서 나타낸다.

4.2 판단 대상 노면 선정

판단 대상 노면은 5가지로 선정하였다. 일반적으로 가장 많이 존재하는 일반범용로 그리고 산길에 많이 존재하는 장파로를 판단 대상 노면으로 선정하였다. 국토교통부 자료인 ‘2011~2015 고속 및 일반국도 포트홀 발생현황’ 자료를 보면 5년간 포트홀이 36만건이 넘게 발생했다고 나타났다. 따라서 맨홀 및 포트홀을 판단 대상 노면으로 선정하였다. 또한 과속을 방지하기 위한 범프 그리고 도로 곳곳에 존재하는 배수로 또한 판단 대상 노면에 포함시켰다. 범프 같은 경우에는 건설교통부에서 지정한 각기 다른 크기의 3가지 범프를 선정하였다. 판단 대상 노면은 Figure 4.1.1에서 나타내고 있다.



Figure 6.1.1 판단 대상 노면

실차 데이터를 얻기 위해 실차에 탑재되어있는 In vehicle sensor들을 사용하였다. Suspension 관련하여 5가지 센서 데이터 정보 그리고 vehicle motion 관련하여 10가지 센서, 총 15가지 센서 데이터를 취득하였다. 데이터 종류는 2장의 Table 2.1.1에서 보이고 있다.

또한, CNN은 supervised learning으로서 답을 주고 학습을 시키는 원리를 가진다. 따라서 각 노면에 대한 답을 주는 작업, 즉 노면에 대한 각각의 라벨링이 필요하다. 판단 대상 5가지 노면에 대한 라벨링은 Table 4.1.1과 같이 진행하였다.

노면종류	일반 범용로	장파로	맨홀 및 포트홀	범프	배수로
Label	0	1	2	3	4

Table 4.1.1 노면 상태에 따른 라벨링

4.3 실차 데이터 기반 노면 판단 결과

4.3.1 일반 범용로 판단 결과

노면 상태 중 가장 많이 존재하는 일반 범용로는 전체 95%의 판단 정확도를 나타내고 있다. Figure 4.3.1은 일반 범용로에서 자유속도로 달렸을 때 판단 정확도를 나타내고 있으며 99.8%의 판단 정확도를 나타내고 있다. 전체 95%의 의미는 다른 노면 상태 도중 존재하는 일반 범용로까지 포함한 판단 정확도를 의미한다.

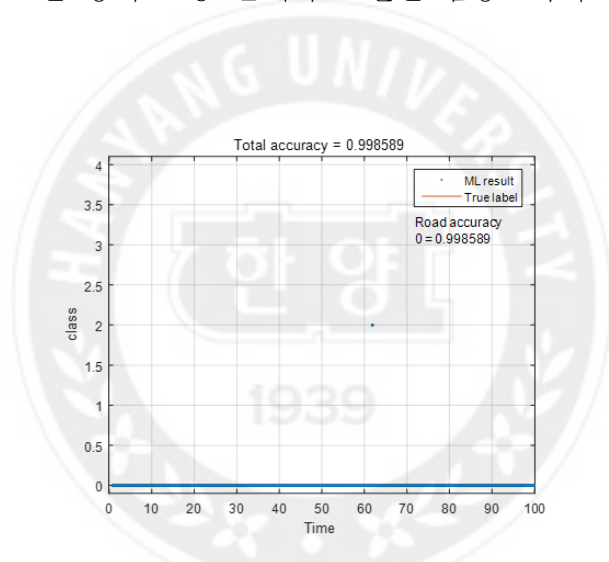



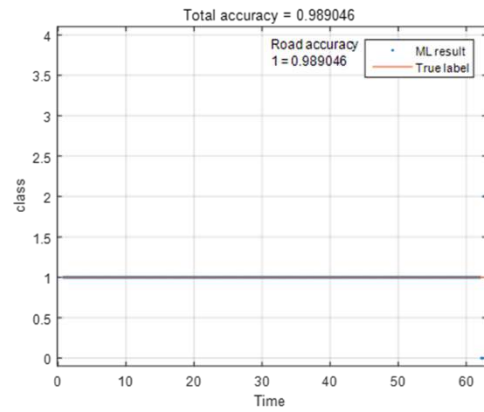
Figure 4.3.1 일반 범용로 판단 결과

4.3.2 일반 범용로 판단 결과


장파로 판단 결과는 97.8%의 정확도를 나타내었다. 모든 속도에서 97% 이상의 높은 판단 정확도를 확보하였다. Figure 4.3.2에서 속도에 따른 판단 결과를 나타낸다.



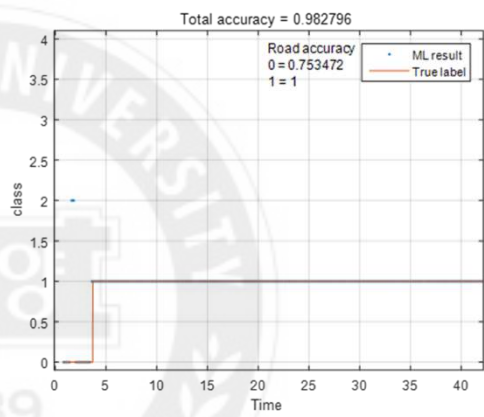
(a) 장파로(20kph) 판단 결과



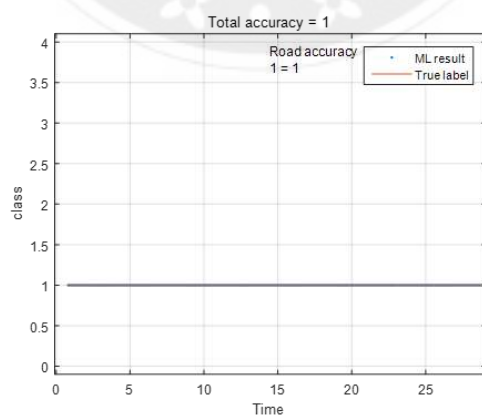
(b) 장파로(30kph) 판단 결과



(c) 장파로(40kph) 판단 결과



(d) 장파로(50kph) 판단 결과



(e) 장파로(60kph) 판단 결과

Figure 4.3.2 장파로 판단 결과

4.3.3 배수로 / 맨홀 및 포트홀 판단 결과

배수로와 맨홀 및 포트홀 같은 경우에는 노면의 상황이 배수로 6개가 먼저 나온 후, 맨홀 및 포트홀로 이루어진 도로로 구성되어있다. 따라서 위의 두 가지 노면 상태를 하나의 그래프에서 결과를 보일 수 있다.

맨홀 및 포트홀의 판단 정확도는 80.2%를 나타냈으며, 배수로의 판단 정확도는 55.2%를 나타내고 있다. 결과 그래프는 Figure 4.3.3에서 보인다.

배수로 같은 경우에 전체 판단 정확도가 55.2%로 낮은 판단 정확도를 보인다. 배수로 같은 경우에는 굉장히 짧은 시간 안에 차가 지나가기 때문에 데이터를 취득하는 정도가 다른 노면에 비해 낮았다. 배수로 / 맨홀 및 포트홀에 대한 훈련 데이터 개수를 Table 4.3.1에서 나타내고 있는데 10배가 넘는 차이를 보인다. 이러한 데이터 개수 차이로 인해 배수로의 판단 정확도가 다른 노면에 비해 낮다고 분석할 수 있다.

노면 상태 (라벨링)	훈련 데이터 개수 (개)
배수로 (4)	190,986
맨홀 및 포트홀 (2)	12,200

Table 4.3.1 노면 상태에 따른 훈련 데이터 개수 비교

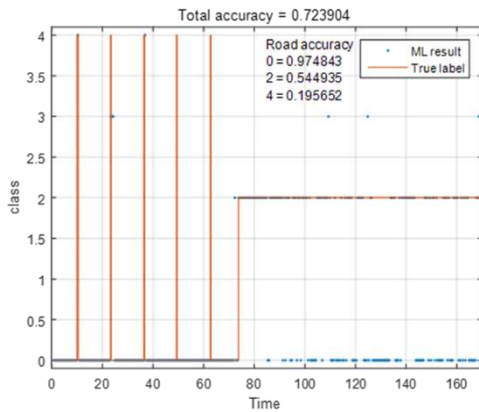
또한 속도에 따른 정확도를 분석해보면 아래 Table 4.3.2에서 보이고 있다. 맨홀 및 포트홀 노면 상태에서 30kph 이상일 때와 미만일 때 정확도 차이가 큰 것을 볼 수 있다. Table 4.3.2를 보면 30kph 이상일 때는 모두 95% 이

상의 판단 정확도를 나타낸다. 이에 반해 15kph 일 때는 54.5%의 낮은 판단 정확도를 나타내고 있으며 20kph 일 때는 88%의 판단 정확도를 나타내고 있다.

실제로 맨홀 및 포트홀 노면 상태의 경우 맨홀 포트홀이 없는 부분은 일반 범용로로 이루어져 있다. 하지만 라벨링 진행시에는 차량이 현재 어느 부분에 있는지 정확히 알 수 없기에 맨홀 및 포트홀 그리고 일반 범용로에 대한 세세한 라벨링을 하기에 한계점이 있다. 따라서 속도에 따라 맨홀과 포트홀을 밟는 시점이 달라지게 되며 저속일 때는 그만큼 느리게 밟기 때문에 판단 정확도가 저하된다.


속도	판단 정확도 (단위:%)	
	맨홀 및 포트홀	
15kph	54.49	
20kph	88.00	
30kph	95.70	
40kph	97.00	
45kph	97.48	
50kph	97.03	

Table 4.3.2 맨홀 및 포트홀 노면 상태의 속도에 따른 정확도 비교




(a) 배수로 / 맨홀 및 포트홀

(15kph) 판단 결과



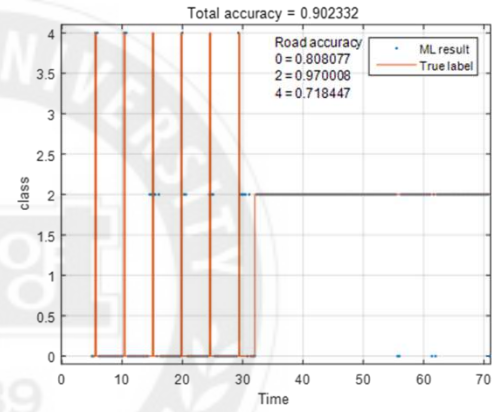
(b) 배수로 / 맨홀 및 포트홀

(20kph) 판단 결과




(c) 배수로 / 맨홀 및 포트홀

(30kph) 판단 결과




(d) 배수로 / 맨홀 및 포트홀

(40kph) 판단 결과



(e) 배수로 / 맨홀 및 포트홀

(45kph) 판단 결과



(f) 배수로 / 맨홀 및 포트홀

(50kph) 판단 결과

Figure 4.3.3 배수로 / 맨홀 및 포트홀 판단 결과

4.3.4 범프 판단 결과

범프의 전체 판단 정확도는 94.6%를 나타내고 있다. 건설교통부 기준 1,2,3의 범프로 학습을 실시할 때는 10kph, 20kph, 30kph의 세가지 속도에 대하여 진행하였다. 범프 판단 결과를 Figure 4.3.3에서 보이고 있다.

학습을 완료한 알고리즘으로 실차 데이터 기반으로 검증할 때는 Table 4.3.3에서 보이는 바와 같이 25kph, 35kph에 대해서도 판단 정확도를 분석해보았다. 35kph일 때 83%로 다른 속도에 비해 낮은 판단 정확도를 나타내고 있다. 이는 약간의 오버피팅 현상이 발생하였다고 볼 수 있다.

범프 시나리오	건교부 기준 1,2,3 판단 정확도 (%)
10kph	96.8
20kph	95.9
25kph	93.8
30kph	97.8
35kph	83.1

Table 4.3.3. 속도에 따른 범프 시나리오 구성 및 판단 정확도


Table 4.3.3에서 보인 학습하지 않은 속도 시나리오에 대한 결과 뿐 아니라 학습하지 않은 다른 범프에 대한 결과 또한 분석해보았다. 범프에 대해 학습을 진행할 때는 건설교통부 기준 1,2,3을 학습 대상으로 선정하였지만 실차 데이터 기반 검증 시에는 낮고 긴 볼록 범프와 낮고 긴 오목 범프에 대한 판

단 결과도 분석해보았다. 이에 대한 판단 결과를 Table 4.3.4와 Figure 4.3.5에서 나타내고 있다. 학습에 사용한 3가지 범프에 대한 판단 정확도를 나타낸 Table 4.3.3과 학습에 사용하지 않은 2개의 범프 까지 포함했을 때의 판단 정확도를 나타는 Table 4.3.4를 비교해보면 큰 차이가 나는 것을 볼 수 있다.


학습하지 않은 범프들은 학습한 범프들과 형상은 달랐지만 차량의 거동은 비슷한 형상을 띄었다. 하지만 학습하지 않은 범프들을 추가시켰을 때 판단 정확도가 낮아진 다른 속도에서의 정확도 저하문제와 같은 오버피팅 현상 때문이라고 판단할 수 있다. 이를 방지하기 위해 다른 기법이나 알고리즘의 더욱 고도화된 최적화가 필요하다고 예상된다.

범프 시나리오	학습하지 않은 범프 2 개를 포함한 전체 5 개 범프의 판단 정확도 (%)
10kph	62.6
20kph	75.8
25kph	79.7
30kph	80.0
35kph	56.9

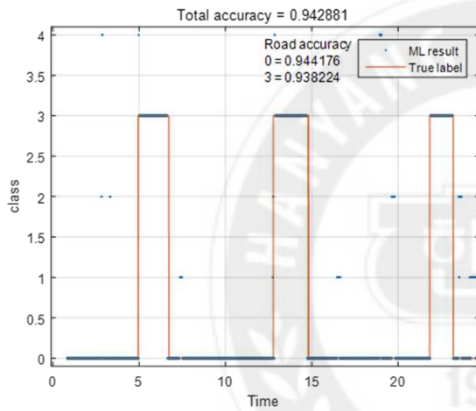
Table 4.3.4 학습하지 않은 범프를 포함한 판단 결과



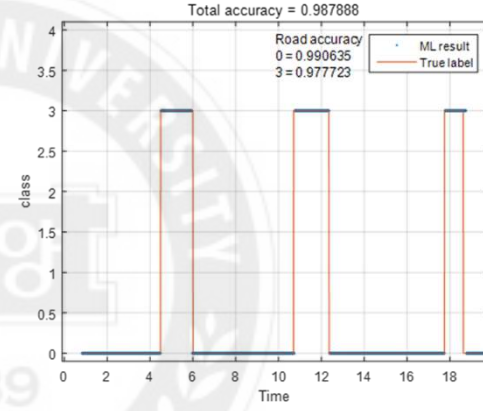
(a) 범프(10kph) 판단 결과




(b) 범프(20kph) 판단 결과



(c) 범프(25kph) 판단 결과




(d) 범프(30kph) 판단 결과




(e) 범프(35kph) 판단 결과

Figure 4.3.4 범프 판단 결과




(a) 학습하지 않은 범프 포함

(10kph) 판단 결과




(b) 학습하지 않은 범프 포함

(20kph) 판단 결과




(c) 학습하지 않은 범프 포함

(25kph) 판단 결과



(d) 학습하지 않은 범프 포함

(30kph) 판단 결과



(e) 학습하지 않은 범프 포함

(35kph) 판단 결과

Figure 4.3.5 학습하지 않은 범프를 포함한 판단 결과 그래프

4.3.5 전체 판단 결과

전체 판단 정확도는 91.18%를 나타내고 있으며 아래 Table 4.3.5에서 정확한 수치를 나타내고 있다. 표의 음영부분이 true-positive 값을 나타내며, 나머지 부분이 true-negative를 의미한다.

		Estimated label				
		0	1	2	3	4
True label	0	95	0	3.3	0	0
	1	2.1	97.8	0	0	0
	2	18.7	0	80.2	0	0
	3	4.1	1.2	0	94.6	0
	4	28.8	0	5.7	10.4	55.2

Table 4.3.5. 각 노면에 대한 판단 정확도

제5장 결론

본 논문은 능동 현가장치 제어 전략 수립에 도움을 주고자 노면 판단에 대한 연구를 진행한 논문이다. 분류 대상 노면 5가지에 대해 현재 차량이 지나고 있는 노면에 대한 판단을 위하여 딥 러닝 기법을 사용하였다.

딥 러닝 기법 중 특징 추출에 강점이 있는 CNN을 사용하여 노면 분류 알고리즘을 설계하였다. 노면 판단 정확도 향상을 위해 최적화된 CNN기반 알고리즘을 제시하였다.

CNN의 입력으로는 비용 측면의 절감을 위하여 차량의 내부 센서들만을 사용하였다. 입력으로 사용한 여러 센서들 중에서, 어떠한 센서가 노면 분류에 있어서 중요한 인자인지에 대한 feature selection 연구를 진행하였다. 총 15개의 센서 중 feature selection을 통해 7개의 센서만을 중요한 인자로 선택하였다.

Feature selection으로 선택한 센서 입력들과 학습된 CNN 알고리즘을 이용한 실차 기반 데이터 검증 결과 91.18%의 노면 판단 정확도를 얻었다.

참고문헌

- 1) EM Dupont, CA Moore, EG Collins and E Coyle, "Frequency response method for terrain classification in autonomous ground vehicles", *Autonomous Robots*, vol. 24, Issue 4, pp.337-347, May 2008
- 2) Ali Solhmirzaei, Shahram Azadi and Reza Kazemi, "Road profile estimation using wavelet neural network and 7-DOF vehicle dynamic systems", *Journal of Mechanical Science and Technology*, vol. 26, Issue 10, pp.3029-3036, Oct.2012
- 3) Moustapha Doumiati *et al.*, "Estimation of road profile for vehicle dynamics motion: experimental validation", American Control Conference, June 2011
- 4) Nicole Challita, Mohamad Khalil and Pierre Beauseory, "New feature Selection method based on neural network and machine learning", IMCET, Nov.2016
- 5) A. Gonzalez and E.J. O'Brien, "The use of vehicle acceleration measurements to estimate road roughness", *Vehicle System Dynamics*, Vol.46, No.6, June, 2008, 483-499
- 6) Viengnam Douangphachanh and Hiroyuki Oneyama, "Formulation of a Simple Model to Estimate Road Surface Roughness Condition from Android Smartphone Sensors", ISSNIP, 2014.
- 7) Wei Mou and Alexander Kleiner, "Online learning terrain classification for adaptive velocity control", Safety Security and Rescue Robotics, July, 2010.
- 8) <http://www.wildml.com/2015/11/understanding-convolutional-neural-networks-for-nlp/>

ABSTRACT

Algorithm for Road Condition Classification Using Deep Learning

Woosung Lee

Directed by Prof. Kunsoo Huh

Department of Automotive Electronics and Control Engineering

The Graduate School of Hanyang University

This paper proposes algorithm for road condition classification based on deep learning. For making suspension control strategy, knowing road condition that vehicle is driving is important. The proposed algorithm helps to classify road condition based on vehicle's IMU sensors. Algorithm is consists of two parts. First, feature selection. Proposed algorithm uses features as IMU sensors and it is necessary to determine which sensor is important. To reduce network size and secure classification accuracy, feature selection method is proposed. Second, deep learning algorithm. Deep learning is useful technology for classification by learning multi-layer structure. It has advantage of increasing road condition classification accuracy and it can consider IMU sensors at once. Deep learning network is designed using convolutional neural network which has strong point in feature extraction. Proposed algorithm is validated through rear vehicle experiments.

감사의 말

2016년 1월에 기계감지 및 제어 연구실의 신입생으로 들어와 2년 간의 여정을 마무리 지으며, 저에게 도움을 주신 분들께 감사의 글을 올립니다.

가장 먼저 저를 2년간 성장하게 지도해주시고 많은 지원을 해주신 허건수 교수님께 감사의 말씀을 드립니다.

연구 주제를 정하고 함께 수행하면서 많은 도움을 주신 종원 선배님, 규식 선배님, 하영 선배님께 진심으로 감사의 말씀을 드리고 싶습니다. 또한 연구실을 잘 이끌어주신 승기 선배님, 창섭 선배님, 현규 선배님, 현재 방장 경식 선배님, 장희 선배님, 같이 연구실 과제를 수행하고, 모르는 것을 잘 알려주었던 정민 선배님, 정근 선배님, 동찬 선배님, 유호 선배님, 성환 선배님께 모두 감사의 말씀을 드리고 싶습니다. 그리고 항상 열심히 하는 모습을 보이며 저를 자극시켜주고 앞으로 더 많은 것을 경험하고 공부하게 될 승목, 현섭, 진호, 인한, 기훈, 동준이 형에게도 감사의 말씀을 전합니다. 특히, 2년간 동고동락하고 서로 이끌고 밀어주면서 이렇게 성장하도록 도와준 사랑하는 동기들 계환이 형, 선우 형, 찬욱이에게 고마움을 표하고 싶습니다. 그리고 힘들 때 마다 항상 곁에 있어주고 응원해주던 친구들에게도 고맙다는 말을 남기고 싶습니다. 덕분에 제가 이 순간까지 올 수 있었다고 생각합니다.

마지막으로, 저를 지금까지 잘 키워주시고 항상 하고 싶은 일을 응원해주며 묵묵히 격려해주신 아버지와 어머니, 하나뿐인 여동생 그리고 가족 모두에게 사랑하고 감사하다는 말을 남기고 싶습니다. 앞으로도 항상 긍정적이고 자랑스러운 아들, 오빠가 되도록 하겠습니다. 감사합니다.

2017년 12월 21일

이우성 올림

연구 윤리 서약서

본인은 한양대학교 대학원생으로서 이 학위논문 작성 과정에서 다음과 같이 연구 윤리의 기본 원칙을 준수하였음을 서약합니다.

첫째, 지도교수의 지도를 받아 정직하고 엄정한 연구를 수행하여 학위논문을 작성한다.

둘째, 논문 작성시 위조, 변조, 표절 등 학문적 진실성을 훼손하는 어떤 연구 부정행위도 하지 않는다.

셋째, 논문 작성시 논문유사도 검증시스템 "카피킬러"등을 거쳐야 한다.

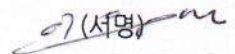
2017년12월15일

학위명 : 석사

학과 : 자동차전자제어공학과

지도교수 : 허건수

성명 : 이우성

 (서명)

한 양 대 학 교 대 학 원 장 귀 하

Declaration of Ethical Conduct in Research

I, as a graduate student of Hanyang University, hereby declare that I have abided by the following Code of Research Ethics while writing this dissertation thesis, during my degree program.

"First, I have strived to be honest in my conduct, to produce valid and reliable research conforming with the guidance of my thesis supervisor, and I affirm that my thesis contains honest, fair and reasonable conclusions based on my own careful research under the guidance of my thesis supervisor.

Second, I have not committed any acts that may discredit or damage the credibility of my research. These include, but are not limited to : falsification, distortion of research findings or plagiarism.

Third, I need to go through with Copykiller Program(Internet-based Plagiarism-prevention service) before submitting a thesis."

DECEMBER 15, 2017

Degree : Master

Department : DEPARTMENT OF AUTOMOTIVE ELECTRONICS & CONTROL
ENGINEERING

Thesis Supervisor : KUN SOO HUH

Name : Lee Woo Sung

 (Signature)